

Análisis Exhaustivo de la Aplicación de Regresión Simbólica y PySR en la Teoría de Conjuntos Causales (Causal Set Quantum Gravity)

Resumen Ejecutivo

El presente informe de investigación analiza exhaustivamente la literatura académica, repositorios computacionales y registros de conferencias para determinar si la regresión simbólica, específicamente mediante la biblioteca PySR o SymbolicRegression.jl, ha sido aplicada a la Teoría de Conjuntos Causales (Causal Set Theory). Tras una rigurosa depuración semántica, se concluye que existe una ausencia total de evidencia directa sobre el uso de PySR en este dominio específico de la gravedad cuántica. Las coincidencias en los motores de búsqueda obedecen a artefactos de indexación web y menciones teóricas no aplicadas. Sin embargo, existe una abundante evidencia indirecta que demuestra la penetración del aprendizaje automático (Machine Learning) en los conjuntos causales, con trabajos seminales utilizando redes neuronales para estimación dimensional y detección de anomalías topológicas. Dada esta base, la aplicación de PySR representa una frontera inexplorada y altamente viable para derivar reglas analíticas interpretables sobre características críticas de los conjuntos causales, tales como correcciones al estimador de Myrheim-Meyer, la densidad de enlaces, y la formulación de un puntaje de similitud a variedades (manifoldlikeness score) que penalice las configuraciones entrópicas de Kleitman-Rothschild.

Fundamentos del Paradigma Cuántico y la Regresión Simbólica

La búsqueda de una teoría unificada de la gravedad cuántica es uno de los pilares centrales de la física teórica contemporánea. Entre los diversos enfoques propuestos, la Teoría de Conjuntos Causales (Causal Set Theory o CST), introducida en la década de 1980 por Sorkin, Bombelli, Lee y Meyer, postula que el espaciotiempo no es un continuo diferenciable, sino una estructura fundamentalmente discreta a la escala de Planck.¹ En este paradigma, el espaciotiempo está compuesto por "átomos" o eventos discretos que están interconectados por una relación de orden parcial que dicta la estructura causal del universo.¹ La belleza de este enfoque radica en su simplicidad axiomática: la cinemática de la teoría se reduce a la combinatoria de un conjunto parcialmente ordenado (poset), donde el orden proporciona la topología causal y el conteo de elementos proporciona el volumen espaciotemporal.

No obstante, la transición de la cinemática discreta a una dinámica que recupere la Relatividad General en el límite continuo ha presentado desafíos computacionales y analíticos formidables.

Es en la intersección de estos desafíos donde las técnicas algorítmicas modernas han comenzado a jugar un papel crucial. Simultáneamente a estos desarrollos en física fundamental, la inteligencia artificial ha experimentado un cambio de paradigma hacia la interpretabilidad. La regresión simbólica, formalizada en herramientas computacionales de alto rendimiento como PySR y SymbolicRegression.jl por investigadores como Miles Cranmer, se erige como una alternativa superior a las redes neuronales de caja negra.² Utilizando programación genética optimizada, la regresión simbólica explora el espacio de expresiones matemáticas para encontrar la función analítica exacta que rige un conjunto de datos, equilibrando la precisión con la parsimonia o complejidad estructural.

La integración conceptual entre conjuntos causales y regresión simbólica sugiere un matrimonio metodológico perfecto: los conjuntos causales proporcionan los datos combinatorios crudos del espaciotiempo pre-geométrico, y la regresión simbólica proporciona el mecanismo para destilar ecuaciones de campo, Lagrangianos discretos y funcionales topológicos a partir de dichos datos. El propósito de este informe es determinar el estado actual empírico e investigativo de esta intersección, discriminando entre la evidencia real, las coincidencias semánticas y el potencial teórico no explotado.

Depuración Semántica y Fronteras Terminológicas

Antes de proceder a la evaluación de las pruebas documentales, el rigor analítico exige establecer fronteras léxicas estrictas, dado que la minería de datos en la literatura de la física y la informática tiende a generar agrupaciones basadas en colisiones semánticas. La investigación de la intersección entre "causal sets" y "machine learning" revela múltiples falsos positivos que deben ser aislados y descartados sistemáticamente.

En primer lugar, es imperativo distinguir la Teoría de Conjuntos Causales de la disciplina estadística conocida como Inferencia Causal (Causal Inference). La inferencia causal, formalizada en gran medida por Judea Pearl, utiliza grafos acíclicos dirigidos (DAGs) para modelar y descubrir relaciones de causa y efecto entre variables probabilísticas clásicas.³ Dentro de este dominio estadístico, y particularmente en la bioinformática y la genómica epidemiológica, se emplea frecuentemente el término exacto "causal sets" (o "credible causal sets") para referirse a conjuntos de variantes genéticas que tienen una alta probabilidad de contener un efecto causal verdadero sobre un fenotipo determinado.⁴ Herramientas bayesianas como *Sum of Single Effects* (SuSiE) identifican estos conjuntos causales en estudios de asociación del genoma completo.⁴ Asimismo, en modelos de recomendación y arquitecturas de incrustación de conocimiento (embedding learning), se habla de "causal embeddings" para discriminar correlaciones espurias de factores causales.⁵ Es fundamental comprender que esta literatura no guarda ninguna relación matemática, física ni conceptual con la gravedad cuántica. Las menciones de "causal sets", "machine learning" y "embeddings" en este contexto son exclusivas del análisis de datos clásicos y han sido excluidas de la evidencia de gravedad cuántica.

En segundo lugar, se debe considerar el error tipográfico recurrente en la literatura

computacional: "casual sets" o "casual graphs" en lugar de "causal". Un ejemplo notable de este fenómeno se observa en los registros del Wolfram Summer y Winter School, donde proyectos que modelan la geometría discreta y la congruencia geodésica titulan sus investigaciones empleando el término erróneo "casual".⁷ Debido a que el ecosistema de Wolfram Physics explora la emergencia del espaciotiempo a partir de hipergrafos evolutivos, un concepto ontológicamente paralelo a la Teoría de Conjuntos Causales, se ha aplicado una corrección heurística para incluir estos trabajos si su contenido matemático subyacente resulta pertinente al análisis, a pesar de la divergencia ortográfica.

Análisis de Evidencia Directa: PySR y SymbolicRegression.jl

La fase primaria de este análisis se centró en identificar evidencia directa e innegable de la aplicación de PySR o SymbolicRegression.jl a las estructuras discretas de la gravedad cuántica. El escrutinio de bases de datos de preprints, repositorios de código abierto como GitHub, disertaciones doctorales y actas de congresos internacionales revela una carencia absoluta de aplicaciones prácticas publicadas.

El Artefacto de Indexación de la Royal Society

Una parte significativa de los resultados arrojados por los motores de búsqueda al cruzar los términos "Miles Cranmer", "PySR", "SymbolicRegression.jl" y "causal sets" remite de manera uniforme a los dominios de la *Royal Society*.² Un examen forense de la arquitectura de la información de esta página web demuestra que estas coincidencias no representan una investigación conjunta, sino un artefacto algorítmico derivado del diseño del sitio.

El documento central indexado describe una reunión de discusión científica programada para abril de 2025 titulada "*Symbolic regression in the physical sciences*".² Este evento, organizado por investigadores prominentes, tiene como objetivo reunir a expertos en aprendizaje automático y físicos para discutir modelos interpretables. Entre los ponentes figura el Dr. Miles Cranmer, cuyo enfoque se centra en presentar la evolución conceptual y la modularidad técnica de SymbolicRegression.jl y PySR, incluyendo aumentos de biblioteca mediante modelos de lenguaje (LaSR).²

Sin embargo, en los metadatos de la página, en los paneles laterales de navegación o en el pie de página promocional, la institución enlista reuniones científicas futuras y pasadas. Una de estas reuniones futuras, programada para septiembre de 2026, lleva por título "*The path to quantum gravity with causal sets*".² Los indexadores de los motores de búsqueda rastrearon y colapsaron el contenido principal sobre regresión simbólica con los enlaces secundarios de promoción institucional, generando un falso positivo masivo. La revisión del programa del evento de regresión simbólica no muestra ninguna charla dedicada a la geometría discreta o gravedad cuántica, y a la inversa, el evento sobre conjuntos causales no lista a Cranmer ni a la regresión simbólica en su agenda.²

Marcos Teóricos Especulativos y Citas Radiales

Más allá de los artefactos de rastreo web, existen menciones periféricas en manuscritos que proponen "teorías del todo" no convencionales. Un caso ilustrativo es el manuscrito que describe el marco UTFANSWF, un sistema conceptual que intenta vincular la teoría de la información, la cosmología y el aprendizaje automático.⁸ En este documento, el autor discute filosóficamente la utilidad de la regresión simbólica para inferir fórmulas analíticas a partir de simulaciones (como las tasas de evaporación de agujeros negros) y, en la misma argumentación, destaca la Teoría de Conjuntos Causales por su capacidad de mantener la invariancia de Lorentz local sin introducir marcos de referencia preferidos.⁸ Además, menciona explícitamente el uso de estimadores topológicos de conjuntos causales, como el estimador de Myrheim-Meyer, para recuperar la dimensión efectiva del espaciotiempo a partir de la estructura de orden.⁸

De manera similar, los documentos asociados a la "Zero-Variance Theory" (ZVT) abogan por el descubrimiento impulsado por datos y la regresión simbólica para unificar la Relatividad General y la Teoría Cuántica, postulando a la Teoría de Conjuntos Causales como un régimen límite de su formalismo matemático.¹⁰ A pesar de la proximidad lingüística, es crucial determinar que estas citas son puramente discursivas. Ninguno de estos marcos teóricos aporta evidencia metodológica, conjuntos de datos procesados, cuadernos computacionales o ejecuciones algorítmicas que demuestren que PySR haya sido entrenado utilizando matrices causales. Son declaraciones especulativas sobre lo que la inteligencia artificial *podría* lograr en la gravedad cuántica, no registros empíricos de lo que se ha logrado.

Análisis de Evidencia Indirecta: Aprendizaje Automático en Conjuntos Causales

La ausencia de uso directo de PySR no implica que la comunidad científica haya ignorado la analítica de datos algorítmica. Por el contrario, el análisis revela que la evidencia indirecta es sustancial y metodológicamente rica. La aplicación de arquitecturas de aprendizaje automático, inferencia estadística y minería de grafos a la gravedad cuántica discreta ha sido objeto de investigaciones doctorales y conferencias de alto perfil. Estas aproximaciones indirectas demuestran la viabilidad computacional de la extracción de observables de los *causets* y establecen las bases funcionales sobre las cuales la regresión simbólica debería operar de forma natural.

Redes Neuronales Profundas para Predicción Dimensional (Will Cunningham)

La estimación de la dimensión macroscópica de un conjunto causal es uno de los problemas fundamentales de la cinemática de CST. Tradicionalmente, esto se realiza mediante estimadores estadísticos analíticos. Sin embargo, en el marco de la investigación sobre gravedad cuántica computacional, Will Cunningham ha sido pionero en la aplicación explícita

de Redes Neuronales Profundas (Deep Learning) a los conjuntos causales.¹¹

En su investigación, presentada en conferencias como las celebradas en el instituto Nordita, Cunningham generó artificialmente conjuntos causales incrustables en espaciotiempos de Minkowski de dimensiones conocidas ($d = 2, 3$ o 4) utilizando algoritmos de dispersión de Poisson (Poisson sprinkling).¹¹ Estas matrices causales discretas, que codifican puramente las relaciones relacionales de los eventos, fueron suministradas como datos de entrenamiento a una red neuronal profunda. El modelo de aprendizaje automático logró aprender las correlaciones topológicas ocultas en los datos discretos y fue capaz de clasificar con éxito la dimensión del conjunto causal de entrada.¹¹

Este trabajo es monumental porque prueba empíricamente que los algoritmos de retropropagación pueden internalizar la topología causal. Sin embargo, en la literatura especializada también se formulan críticas metodológicas hacia este enfoque de "caja negra".¹¹ Se argumenta que la caracterización de la dimensión obtenida por la red neuronal podría haberse logrado con menor coste y mayor transparencia analítica utilizando herramientas preexistentes en CST, como el estimador de Myrheim-Meyer o la abundancia de intervalos.¹¹ Esta es precisamente la debilidad epistemológica de las redes neuronales estándar en la física teórica: predicen el resultado pero no revelan la ecuación subyacente. La regresión simbólica no padecería de este defecto, justificando la necesidad técnica de reemplazar o suplementar las redes neuronales de Cunningham con herramientas como PySR.

Detección de Anomalías y la Medición de "Manifoldlikeness" (Miremad Aghili)

La tesis doctoral de Miremad Aghili (2019), titulada "*Manifoldlike Causal Sets*", desarrollada en la Universidad de Mississippi bajo la dirección de teóricos prominentes como Luca Bombelli, se centra en un problema dinámico y estadístico crucial: la dominancia entrópica de los conjuntos causales que no se asemejan a una variedad.¹ Cuando se permite que un universo discreto crezca estocásticamente, la inmensa mayoría de las configuraciones resultantes no pueden incrustarse en una variedad diferenciable (non-manifoldlike causets).¹⁴ Para que el límite continuo reproduzca la Relatividad General, se requiere un mecanismo que penalice sistemáticamente estas configuraciones en la función de partición o en el Lagrangiano de la teoría.

Aghili introduce la distribución estadística de la "longitud del camino" (path length distribution) entre puntos relacionados causalmente para asignar una medida cuantitativa rigurosa a la propiedad de *manifoldlikeness*.¹ Las simulaciones numéricas demostraron que los conjuntos causales generados mediante dispersión uniforme en una variedad exhiben posiciones de pico y anchos de distribución específicos y predecibles.¹

De vital importancia metodológica es la propuesta explícita en el trabajo de Aghili de diseñar una función de acción (análoga a la acción de Benincasa-Dowker) inspirada en los algoritmos de Machine Learning utilizados para la **detección de anomalías**.¹ Aghili, quien posee una

certificación especializada y entrenamiento comprobado en algoritmos de ML como *Support Vector Machines*, *Random Forests*, y regresión logística¹, estructura el problema

espacializando los datos: la posición del pico (k_0), el ancho de la distribución (Δ) y el número total de caminos generan un "espacio de parámetros" (parameter space).¹ En este espacio hiperdimensional, los conjuntos causales *manifoldlike* ocupan una región hiperespecífica, y cualquier desviación se clasifica computacionalmente como una anomalía topológica.¹ Este tratamiento empírico de las distribuciones topológicas como vectores de características (feature vectors) de Machine Learning es evidencia contundente de la aplicabilidad de algoritmos de optimización para derivar reglas de selección de espaciotiempos viables.

Análisis de Redes Complejas y Curvatura Ollivier-Ricci (DK-Lab)

El análisis formal de la topología causal ha atraído a investigadores especializados en ciencias de redes. El laboratorio dirigido por Dmitri Krioukov estudia la intersección del análisis científico de redes, el aprendizaje automático y la teoría de cuerdas / gravedad cuántica.¹⁵ La hipótesis de investigación operativa de este equipo es que la red causal que representa la estructura a gran escala de nuestro universo en expansión acelerada exhibe la firma combinatoria de un grafo libre de escala (scale-free graph) con un fuerte coeficiente de agrupamiento (clustering).¹⁵

En estudios recientes, investigadores como P. van der Hoorn, G. Lippner y Will Cunningham colaboraron para demostrar que la curvatura de Ollivier-Ricci en grafos geométricos aleatorios converge, bajo el límite continuo, hacia la curvatura de Ricci de sus variedades riemannianas subyacentes.¹⁵ También derivaron algoritmos explícitos para medir distancias espaciales puras en conjuntos causales basándose en la superposición de sus conos de luz pasados y futuros (causal overlaps), así como la construcción del primer operador d'Alembertiano discreto que converge algebraicamente al d'Alembertiano continuo.¹⁵ La formulación rigurosa de estos operadores analíticos refleja el objetivo fundamental de la gravedad cuántica computacional, un objetivo que la regresión simbólica automatizaría al inferir los límites asintóticos a partir de tensores de adyacencia de grafos masivos.

Combinatoria Algebraica y Graph Neural Networks en Períodos de Feynman (Shaban y Balduf)

Una aportación significativa a la literatura interdisciplinaria se encuentra en investigaciones de la Universidad de Waterloo que entrelazan explícitamente la evolución cinemática de los conjuntos causales con la predicción del aprendizaje automático en física de partículas. Esta investigación, ejecutada junto al Dr. Paul-Hermann Balduf, aborda dos mitades del problema discreto cuántico.¹⁶

Por un lado, la tesis estudia en profundidad la combinatoria geométrica necesaria para la evolución secuencial clásica del universo (conocido como *covtree*), resolviendo problemas analíticos de reconstrucción geométrica mediante el estudio de subconjuntos descendentes (downsets) en el caso particular de órdenes parciales de dimensión dos.¹⁶ Por otro lado, la investigación aplica arquitecturas de aprendizaje automático —específicamente **Graph Neural**

Networks (GNNs), regresión lineal y regresión cuadrática— para predecir los periodos de Feynman a partir de las propiedades combinatorias y estructurales de los grafos de Feynman.¹⁶

El hallazgo crítico de que métodos simples de regresión sobre parámetros de grafos pueden lograr predicciones altamente precisas en la Teoría Cuántica de Campos (QFT) eludiendo la intratabilidad computacional tradicional, subraya la filosofía fundamental de aplicar aprendizaje inductivo supervisado a estructuras discretas fundamentales.¹⁶ La aplicabilidad directa de GNNs sobre grafos físicos refuerza la validez metodológica de utilizar el formalismo de matrices adyacentes propio de CST como *input* para marcos de regresión estocástica.

Hipergrafos, Automatas Celulares y Regresión Simbólica Interpretable (Wolfram Physics)

Aunque topológicamente distintos a los conjuntos causales, los modelos propuestos por el Wolfram Physics Project comparten el ethos fundacional de generar gravedad relativista y mecánica cuántica a partir de grafos discretos y reglas de actualización algorítmica. Un indicador irrefutable del creciente interés en la regresión simbólica dentro de la gravedad cuántica discreta surge de los proyectos desarrollados en las escuelas de verano e invierno de Wolfram.

La agenda académica revela que investigadores como Rafael Turner han explorado el puente topológico directo entre la Teoría de Conjuntos Causales y la Física de Wolfram.⁷ Simultáneamente, investigadores como Pei-Xin Shen abordaron el problema directo de la **"Regresión Simbólica Interpretable con Redes de Kolmogorov-Arnold (KANs)"**.⁷ Esto consolida un esfuerzo concertado y estructurado por la comunidad académica periférica de la física computacional para implementar algoritmos evolutivos matemáticos sobre estructuras topológicas no continuas, marcando el preludio exacto a la necesidad técnica que PySR podría cubrir en la investigación puramente centrada en CST.

Tabla Estructurada: Resumen y Clasificación de la Evidencia Empírica

Con el propósito de sintetizar la literatura y los dominios analizados, la siguiente matriz clasifica las interacciones metodológicas abordadas, especificando el uso, el método de ML aplicado, los predictores inferidos y su relevancia estructural.

Autor / Año	Fuente	Usa PySR explícitamente sí/no	Tipo de ML / Método	Qué predice o aprende	Relevancia para causal sets	Enlace
Miles	Royal	NO	Regresió	Descubri	Represen	(https://ro

Cranmer / 2025	Society (Actas de Reunión)		n Simbólica (SymReg) / PySR / LaSR	miento de leyes físicas, modelado de turbulencias y aplicaciones astrofísicas.	ta un falso positivo en búsquedas web por agregación algorítmica; el autor dio una charla teórica sobre SR, sin mencionar CST.	yalsociety.org/science-events-and-lectures/2025/04/symbolic-regression/)
Miremad Aghili / 2019	Tesis Doctoral (Univ. Mississippi)	NO	Detección de Anomalías / Regresión Logística / Random Forests (Propuesto y Formado)	Evalúa si un causet aleatorio es "manifold like" basándose en la distribución de la longitud de caminos.	Relevancia crítica. Sistematiza métricas topológicas (k_0 , Δ) ideales para servir como inputs en una regresión simbólica futura.	eGrove Ole Miss
Will Cunningham /	Conf. Nordita / Papers	NO	Deep Learning / Redes	Predice la dimensión	Demuestra empírica	(https://indico.fysik.su.se/event

2018	Académicos		Neuronal es Profundas (DNNs)	macroscópica subyacente ($d =$) a partir de matrices de adyacencia causal.	mente que algoritmos de caja negra supervisados logran recuperar invariantes topológicos en gravedad discreta.	nt/6242/page/419-sides-from-talks)
Shaban & Balduf / 2023	Tesis Maestría (Univ. Waterloo)	NO	Graph Neural Networks (GNNs), Regresión Lineal/Cuadrática	Estimación de periodos de Feynman; resuelve reconstrucciones del covtree espacial.	Muestra cómo la combinatoria y grafos discretos en altas energías se procesan eficientemente en arquitecturas de regresión polinómica.	(https://uwaterloo.ca/items/26a83106-75b2-4990-aeb2-ea94bd680a11)
Dmitri Krioukov / 2020+	DK-Lab Network Science	NO	Machine Learning aplicado a Redes Complejas	Topología asintótica, curvatura Ollivier-Ricci, espacioti	Formula rigurosamente límites algebraicos continuos	(https://dk-lab.net/research.html?id=3)

				empos de De Sitter a gran escala.	a partir de la estructura gráfica, un objetivo alineado con la regresión analítica.	
Wolfram Physics / 2021-25	Wolfram Summer School Projects	NO	Redes de Kolmogorov-Arnold (KANs), Regresión Simbólica, Automatas	Dinámica de hipergrafos discretos, escalares de Kretschmann y evolución causal.	Extremadamente análogo a CST; confirma el uso empírico naciente de la regresión simbólica sobre espacios topológicos discretos.	(https://www.wolframcloud.com/obj/microsites/summer-school/projects.html)
S.C.F. (UTFANS WF) / 2024	Preprint / Marco Teórico ("Theory of everything")	NO	Regresión Simbólica y ML (Puramente Discursivo)	Conexión de métricas de orden de Myrheim-Meyer con correcciones analíticas.	Marcomeramente descriptivo. Enumera los métodos como viables conceptualmente, sin	(https://rxiverse.org/pdf/2509.0013v5.pdf)

					proporcionar implementación algorítmica ni repositorios.	
--	--	--	--	--	--	--

Relevancia y Potencial Computacional de PySR en las "Features" Diagnósticas de Causal Sets

El hallazgo fundamental de este informe—que existe penetración robusta del aprendizaje automático en los conjuntos causales, pero una usencia total de PySR—señala una laguna tecnológica significativa. El aprendizaje profundo (Deep Learning) ha sido empleado para tareas de clasificación, pero adolece del problema sistémico de la "caja negra". En gravedad cuántica, una predicción numérica aislada es de poca utilidad si no está respaldada por una ecuación matemática interpretable y analíticamente manejable. El programa cinematográfico requiere fórmulas en forma cerrada para calcular escalares, construir Lagrangianos topológicos, y formular funcionales invariantes bajo las transformaciones de Lorentz.

PySR (Python Symbolic Regression) y su motor backend SymbolicRegression.jl implementan un formalismo evolutivo altamente paralizado que busca frentes de Pareto en la optimización conjunta de complejidad algebraica y reducción del error de pérdida. Dado un tensor de

entrada X y un objetivo y , PySR construye árboles de sintaxis abstracta combinando operadores algebraicos y trigonométricos para sintetizar la ley natural no trivial subyacente. A continuación, se detallan las justificaciones físicas y matemáticas rigurosas de cómo PySR transformaría la extracción de reglas simbólicas diagnósticas para las *features* cardinales de la Teoría de Conjuntos Causales, respondiendo explícitamente a las interrogantes planteadas en la parametrización de la investigación.

Estimación Dimensional Estocástica: Myrheim-Meyer y Midpoint Scaling

Determinar la dimensionalidad del colector lorentziano continuo en el que un conjunto causal discreto puede ser inmerso fielmente es un desafío central en CST. El enfoque predeterminado es el método de Myrheim-Meyer.¹ Matemáticamente, este estimador se basa en resultados analíticos puramente teóricos de la abundancia esperada de cadenas completas (camino temporales completamente ordenados) de longitud k , denotada como $\langle C_k \rangle$ en un poset de Minkowski de N elementos. La expresión canónica asintótica depende rigurosamente del

ensamblaje de funciones Gamma euclidianas ¹:

$$\langle C_k \rangle \approx \frac{N^k}{k!} \frac{\Gamma(d+1)}{\Gamma(d/2+1)^{k-1} \Gamma(d)}$$

La complejidad de este estimador radica en que, en el límite continuo, el volumen de los intervalos espaciotemporales se correlaciona perfectamente con estas cadenas. Sin embargo, a escalas cercanas a la longitud de Planck o en ensamblajes de cardinalidad baja (pequeño N), las fluctuaciones cuánticas del espaciotiempo destruyen la validez de esta aproximación asintótica continua plana.¹ Si el espaciotiempo exhibe curvatura intrínseca fuerte, el estimador tradicional de Myrheim-Meyer requiere correcciones perturbativas altamente complejas o se vuelve inoperante.

Aplicabilidad de PySR: Un usuario podría generar decenas de miles de *causets* estocásticos mediante aspersión en variedades fuertemente curvas o en ensamblajes finitos exactos extraídos de *Causal Set Simulators*.¹⁹ Suministrando a PySR los vectores de conteo empírico $\langle C_1 \rangle, \langle C_2 \rangle, \dots, \langle C_k \rangle$, junto con la cardinalidad total N como la matriz de características de entrada, y la dimensión empírica d (o el escalar de curvatura) como variable objetivo, el algoritmo genético podría inferir una **ley analítica corregida no perturbativa**. La regresión simbólica iteraría sobre bases de funciones para derivar expresiones racionales cerradas que suplanten la aproximación puramente plana, un logro matemático inmenso en topología diferencial discreta.²⁰ Del mismo modo, el estimador dimensional de escalado del punto medio (Midpoint Scaling)²¹, el cual infiere la dimensión apoyándose en el tiempo propio geodésico y el volumen del cono de luz, podría modelarse mediante PySR para revelar la ecuación de acoplamiento exacta frente al ruido métrico estocástico.²²

Termodinámica del Poset: Controles KR, Coronas y el Límite de Kleitman-Rothschild

El paradigma dinámico principal de los conjuntos causales se denomina Crecimiento Secuencial Clásico (Classical Sequential Growth - CSG), introducido por Rideout y Sorkin, que detalla un modelo de acreción probabilística para los átomos espaciotemporales.¹⁹ La dificultad de los modelos dinámicos puramente entrópicos es su tendencia patológica a degenerar termodinámicamente. A medida que $N \rightarrow \infty$, el recuento combinatorio masivo del ordenamiento parcial dictamina que la inmensa mayoría de las topologías convergentes pertenecen al tipo de **órdenes de Kleitman-Rothschild (KR)**.¹ Un orden de Kleitman-Rothschild es una estructura no colector (non-manifoldlike) altamente patológica que esencialmente consta de solo tres "capas de tiempo" interconectadas exhaustivamente, donde un subconjunto ínfimo conforma el pasado y el futuro infinito, y la abrumadora mayoría de los eventos espaciotemporales están colapsados en una sola superficie espacial presente masiva. Estructuras topológicas emparentadas como anillos o coronas (crown/corona graphs)

comparten esta degeneración de la dimensionalidad, siendo incompatibles estructuralmente con la Relatividad General.¹

Para contrarrestar la dominancia de los posets KR, los teóricos se ven obligados a imponer controles artificiales ad-hoc o términos de penalización dinámica.

Aplicabilidad de PySR: Determinar si un *causet* específico se aproxima microscópicamente al atractor de Kleitman-Rothschild requeriría de un invariante de control. Suministrando tensores estadísticos topológicos extraídos de los *causets* en evolución y entrenando PySR para que diferencie la entropía del poset frente a datos de *manifoldlikeness* validada, la regresión simbólica podría sintetizar **fórmulas de control simbólico exacto de KR / crown**. Este resultado empírico proporcionaría a los físicos una función de coste analítica natural que puede insertarse directamente en la función de partición del Lagrangiano o en la matriz de Markov del modelo CSG, sofocando las transiciones de fase patológicas microscópicas antes de su proliferación macroscópica.

Estadísticas Microestructurales: Cadenas (Chains), Anticadenas y Densidad de Enlaces (Link Density)

En el nivel topológico primario del conjunto causal, las métricas más directas son observables algebraicos abstractos:

- **Cadenas (Chains):** Secuencias máximamente ordenadas ($x_1 \prec x_2 \prec \dots \prec x_n$). Representan geodésicas causales del tipo tiempo (tiempo propio).¹⁹
- **Anticadenas (Antichains):** Subconjuntos de eventos donde ningún par está relacionado causalmente. Representan rebanadas espaciales (spatial slices) de volumen geodésico máximo.¹⁹
- **Densidad de enlaces (Link Density):** La diferencia empírica en densidad entre el grafo causal transitivamente reducido (donde solo existen conexiones inmediatas sin pasos intermedios, correspondientes a los bordes de Hasse) frente a la matriz causal plena y saturada transitivamente.¹⁹

Estos conteos crudos esconden asintóticamente la métrica de Lorentz.

Aplicabilidad de PySR: Suministrar una matriz plana multidimensional que incluya la varianza de la cadena más larga y la anticadena más grande a SymbolicRegression.jl permitiría destilar un polinomio analítico que vincule la dispersión transversal espacial empírica con el escalar de curvatura intrínseca de forma determinista. Asimismo, correlacionar la *densidad de enlaces (link density)* con el volumen invariante local proveería a la teoría matemática de nuevos invariantes topológicos que antes solo eran descubribles mediante intuición matemática analítica profunda, transformando horas de derivación en un proceso iterativo de máquinas automatizadas.

Funcionales Complejos: Energía de Inmersión y el Límite Continuo

Comprobar teóricamente si un conjunto causal aleatorio discreto $\mathcal{C}$ es isomorfo ordenado (fielmente inmersivo) en una variedad lorentziana $(\mathcal{M}, g)$ mediante una función de densidad probabilística constante P es un proceso algorítmico considerado computacionalmente *NP-hard* en topología.¹⁷ Los simuladores actuales utilizan métodos de Monte Carlo de Cadenas de Markov (MCMC), templado simulado y termodinámica estadística heurística para evaluar la función de coste (denominada habitualmente *Embedding Energy*).¹⁹ Minimizando repetidamente esta energía matemática abstracta se intenta alinear los puntos pre-espaciales contra la variedad rígida de prueba.

Aplicabilidad de PySR: El cálculo microscópico analítico exacto de la "energía de inmersión" subyacente para grafos causales grandes devora un tiempo de procesamiento exponencial. Entrenar PySR sobre cientos de miles de estados de energía generados heurísticamente para diferentes geometrías podría extraer una parametrización de campo medio o un Lagrangiano efectivo. Esta ecuación simbólica de campo medio podría aproximar la energía de inmersión en $O(N)$ o $O(N \log N)$ operaciones geométricas elementales, evadiendo la necesidad de resolver iterativamente la optimización matricial subyacente cada vez que el simulador ejecuta una perturbación dinámica.

El Reto de la Integración de Métricas: Un "Manifoldlikeness Score" Analítico e Interpretable

La integración del esfuerzo analítico culmina en la necesidad teórica y metodológica de formular un puntaje continuo o clasificador exacto unificado: el **Manifoldlikeness Score** (el grado en el que un grafo discreto se comporta estadísticamente como una variedad espaciotemporal suave continua). El ya citado Miremad Aghili implementó el análisis detallado de la distribución de las longitudes de los caminos (k_0, Δ) y el uso explícito de enfoques de aprendizaje automático para delinear el subespacio topológico de soluciones donde ocurren estas configuraciones métricas saludables.¹ Asimismo, la dinámica cuántica exige en la simulación estocástica una fase previa denominada "warmup" destructivo, donde la simulación transcurre quemando las aberraciones topológicas del vacío inicial antes de recoger datos estadísticos métricamente significativos. Cuantificar empíricamente este *warmup destructiveness* (es decir, el nivel de asimetría patológica inicial en la simulación) representa un cuello de botella algorítmico fenomenológico profundo.¹

Aplicabilidad de PySR: Las redes neuronales profundas (como en el enfoque de Cunningham¹¹) resolverían este problema arrojando una probabilidad probabilística cruda de 0 a 1 de similitud a una variedad.¹¹ Sin embargo, la física teórica requiere formulación teórica. PySR podría procesar las entradas masivas de características—el comportamiento fluctuante del estimador de Myrheim-Meyer, las proporciones termodinámicas de antichains, las penalizaciones de Kleitman-Rothschild y la varianza espectral de las densidades de Hasse—y destilar un tensor de clasificación algebraico o un observable analítico escalar puramente

determinista. Este resultado empírico proporcionaría a los físicos un funcional matemático compacto $\mathcal{F}(C)$ interpretable. En lugar de interrogar a una caja negra algorítmica para determinar si un universo naciente sobrevivirá al crecimiento microscópico sin degenerarse térmicamente en un estado crown/corona estéril, el científico poseería una ecuación rigurosa revelando exactamente qué parámetro escalar de Hasse colapsa la variedad geométrica discreta.

Conclusión

El examen de los metadatos institucionales y los archivos bibliográficos contemporáneos conduce a una resolución concluyente: **no he encontrado evidencia** de uso directo en la que un investigador haya aplicado explícitamente algoritmos de PySR o SymbolicRegression.jl a conjuntos de datos derivados de la Teoría de Conjuntos Causales. Las superposiciones de búsqueda resultan ser subproductos sintácticos y agregaciones web causadas por las páginas institucionales de la *Royal Society*.

A la vez, la presente evaluación dictamina que **solo hay evidencia indirecta**, pero esta evidencia subraya un momento transformador en la física cuántica estructural. Investigadores han desplegado ya el análisis de grafos, las redes neuronales densas y heurísticas de detección de anomalías topológicas en la misma geometría pre-espacial. La imposibilidad inherente de las redes neuronales de extraer dinámicas físicas transparentes resalta la carencia del instrumental metodológico preciso que la regresión simbólica fue construida para resolver. Ante las deficiencias analíticas frente al comportamiento fluctuante de métricas complejas, como los límites entrópicos de Kleitman-Rothschild, el recuento variacional de estimadores dimensionales de Myrheim-Meyer y la evaluación termodinámica computacionalmente restrictiva de inmersiones espaciales (embeddings), la adopción de arquitecturas orientadas a descubrimientos de frentes de Pareto simbólicos constituiría el siguiente avance empírico natural dentro de la investigación del espaciotiempo fundamental.

Obras citadas

1. Manifoldlike Causal Sets - eGrove, fecha de acceso: mayo 17, 2026, <https://egrove.olemiss.edu/cgi/viewcontent.cgi?article=2528&context=etd>
2. Symbolic regression in the physical sciences | Royal Society, fecha de acceso: mayo 17, 2026, <https://royalsociety.org/science-events-and-lectures/2025/04/symbolic-regression/>
3. arXiv:1209.0023v1 [quant-ph] 31 Aug 2012, fecha de acceso: mayo 17, 2026, <https://arxiv.org/pdf/1209.0023>
4. Large-scale Mendelian randomization identifies novel pathways as therapeutic targets for heart failure with reduced ejection fraction and with preserved ejection fraction | medRxiv, fecha de acceso: mayo 17, 2026, <https://www.medrxiv.org/content/10.1101/2024.03.22.24304728v1.full-text>
5. Causality Enhancement for Cross-Domain Recommendation - arXiv, fecha de acceso: mayo 17, 2026, <https://arxiv.org/html/2510.14641v1>

6. Learning Faithful Representations of Causal Graphs - ACL Anthology, fecha de acceso: mayo 17, 2026, <https://aclanthology.org/2021.acl-long.69.pdf>
7. Technical Documents: The Wolfram Physics Project, fecha de acceso: mayo 17, 2026, <https://www.wolframphysics.org/technical-documents/>
8. UTFANSWF v21: From Information-Theoretic Foundations to a Testable Unified Framework - rxiVerse, fecha de acceso: mayo 17, 2026, <https://rxiverse.org/pdf/2509.0013v5.pdf>
9. The Merged Quantum Gauge and Scalar Consciousness Framework (MQGT-SCF): A Unified Theory of Physics, Mind - Zenodo, fecha de acceso: mayo 17, 2026, https://zenodo.org/records/15278842/files/MQGT-SCF_Theory_of_Everything_Complete_Publication_Research.pdf?download=1
10. From Eternity to Here: The Quest for the Ultimate Theory of Time | Request PDF - ResearchGate, fecha de acceso: mayo 17, 2026, https://www.researchgate.net/publication/243392225_From_Eternity_to_Here_The_Quest_for_the_Ultimate_Theory_of_Time
11. Quantum Gravity on the Computer: Impressions of a Workshop - MDPI, fecha de acceso: mayo 17, 2026, <https://www.mdpi.com/2218-1997/5/1/35>
12. Quantum Gravity on the Computer (5-9 March 2018): Slides From Talks - Agenda (Indico), fecha de acceso: mayo 17, 2026, <https://indico.fysik.su.se/event/6242/page/419-slides-from-talks>
13. Spatial literary studies : interdisciplinary approaches to space, geography, and the imagination 9780367520106, 0367520109 - DOKUMEN.PUB, fecha de acceso: mayo 17, 2026, <https://dokumen.pub/spatial-literary-studies-interdisciplinary-approaches-to-space-geography-and-the-imagination-9780367520106-0367520109.html>
14. Fluctuations and correlations in causal set theory | Request PDF, fecha de acceso: mayo 17, 2026, https://www.researchgate.net/publication/388314340_Fluctuations_and_correlations_in_causal_set_theory
15. Research - DK Lab, fecha de acceso: mayo 17, 2026, <https://dk-lab.net/research.html?id=3>
16. Combinatorial Aspects of Feynman Integrals and Causal Set Theory - UWSpace - University of Waterloo, fecha de acceso: mayo 17, 2026, <https://uwspace.uwaterloo.ca/items/26a83106-75b2-4990-aeb2-ea94bd680a11>
17. Combinatorial Aspects of Feynman Integrals and Causal Set Theory - UWSpace - University of Waterloo, fecha de acceso: mayo 17, 2026, <https://uwspace.uwaterloo.ca/bitstreams/95ddc3d8-53e7-40bc-a39e-b90410748382/download>
18. Wolfram Summer School Projects, fecha de acceso: mayo 17, 2026, <https://www.wolframcloud.com/obj/microsites/summerschool/projects.html>
19. Causal Set Simulator Project Report | PDF | Applied Mathematics - Scribd, fecha de acceso: mayo 17, 2026, <https://www.scribd.com/document/907530230/Causal-Set-Simulator-Report>
20. Benincasa-Dowker causal set actions by quantum counting | Request PDF -

ResearchGate, fecha de acceso: mayo 17, 2026,
https://www.researchgate.net/publication/392167977_Benincasa-Dowker_causal_set_actions_by_quantum_counting

21. Journal of the Mississippi - Academy of Sciences, fecha de acceso: mayo 17, 2026,
https://msacad.org/wp-content/uploads/2021/07/Vol-66_July_3_Journal-of-MAS_abstract_-Issue2021-Autosaved-7_26_21ffff.pdf
22. Physics Reports The science of science: From the perspective of complex systems, fecha de acceso: mayo 17, 2026,
<https://sss.bnu.edu.cn/docs/2022-04/e47e7220153f4c7aaf14e7ac7a3a6977.pdf>
23. DO PARTICLES EVOLVE? 1. Introduction Ten years have passed since the interacting 'artificial particles' of elementary cellu- - tommaso bolognesi, fecha de acceso: mayo 17, 2026,
<https://tommasobolognesi.wordpress.com/wp-content/uploads/2012/08/dopartic lesevolve.pdf>